# texopt 打分评价体系 · 现状总结

2026-11-02 · 阶段汇报版 · 承接 10-14 的 v3 结构设计说明（`model_v3_design_20261014.html`），补齐阶段 12–16 的标定与修正 · 代码与数字均可在当前仓库复现

> **一句话：**最终排序是**严格字典序** $(|\text{Gate}|, M_1, M_2)$ —— 先用**逻辑门**判「能不能用」，再用 **model1** 判「缺陷与代价是否划算」，最后才用 **model2** 在完全打平时比审美。三条线**不相加**，因为相加允许「审美变好」去补偿「缺陷变多」。

## 0. 当前状态一览

| 模块 | 状态 | 关键事实 |
| --- | --- | --- |
| Gate（逻辑门） | ✅ 冻结 | 10 项检查，分「可修 / 不可修」；页数按**正文页**判；正文改动按用户决定**保持软约束** |
| model1 = ρ·P + I | ✅ 冻结 | ρ 由人工无差异点标定为 **15**（原 0.341 是效率统计量，已废弃）；P 的 11 项里 **7 项**统一到 c* 口径，4 项仍明确标注「先验」 |
| model2 = A_soft + λ·A_profile | ⚠ **进行中** | λ 恒为 0；体检发现 8 个指标里 **3 个是准常数**、**1 个是阈值型**；v2 指标集（3 指标）已定案，权重待人工标定 |
| 局部 / 整体 | ✅ 诊断层已建 | 单页分 + 三种读法（页均 / 最差 5% / 峰值）；**不动 M1 口径**（用户决定不加最差页项） |
| 回归测试 | ✅ 332 通过 / 0 失败 / 0 跳过 | 含连档压页 A/B、归因恒等式、指标体检、权重 artifact 漂移校验 |

## 1. 三层结构与职责

| 层 | 回答什么 | 数学形态 | 参与打分类别 |
| --- | --- | --- | --- |

| | | | |
|---|---|---|---|
| Gate | 这份稿子**算不算可用** | 条件集合，逐项 0/1；**不是公式、不给分** | 一票否决，不进入 $M_1/M_2$ |
| model1 | 页面缺陷有多少？为了改它动了多少？ | $M_1 = \rho \cdot P + I$ | 主目标 |
| model2 | 版面观感如何？（密度 / 空洞 / 均衡，及与同类论文比） | $M_2 = A_{soft} + \lambda \cdot A_{profile}$ （$\lambda=0$） | 次目标，仅作 tie-break |

$$\text{rank}(x') : \Big( |\text{Gate}(x')|,\ M_1(x'),\ M_2(x') \Big) \quad \text{lexicographic (no summation)}$$

## 2. Gate：不可行就不打分

| 检查项 | 判据 | 可修 | 修复手段 |
|---|---|---|---|
| `compile` | 编译失败 / 无 PDF | ✗ | —（不在排版动作面内） |
| `pdf` | 未产出 PDF | ✗ | — |
| `figures` | 图/表内容指纹被改 | ✗ | —（保真底线） |
| `content` | 仅当 `content_hard=True` 才拦 | — | **当前默认软约束**（用户 11-02 决定保留） |
| `pages` | 正文页数超上限（参考文献之前计） | ✓ | 边距 / 字号 / 图宽 / 删手动分页 / 收紧间距 |
| `font` / `margin` | 不符要求档位 / 会议下限 | ✓ | `font_spec` / `margin_spec` |
| `fleqn` / `toc` / `header` | 要求点名但缺失/异常 | ✓ | 对应确定性动作 |

### 2.1 门内定向修复：连档压页的「暂存链」

TeX 断页是**台阶式**的：收一档边距常常一页不减，要连收两三档才兑现。旧逻辑要求 每个单步都严格减页，于是第一档就被回滚并永久拉黑——「多档才减页」的修复永远不可能发生。 阶段 15 改为暂存链：

| 单步结果 | 处理 | 目的 |
|---|---|---|

| | | |
|---|---|---|
| 兑现（违规减少 / 页数减少） | 本步 + 此前所有暂存档**一并提交** | 不丢组合收益 |
| 不增违规、不增页 | **暂存**，保留状态继续往下压 | 允许台阶式推进 |
| 变差（违规变多 / 页数变多） | 回滚 | 不倒退 |
| 暂存达 3 档仍未兑现 | **整链回滚到链首** | 不把累计破坏留在稿子里 |

实测靶稿（8 段 × 6 句，A4/10pt）：25mm→2 页、23mm→2 页、21mm→1 页。 把上限设为 1（= 旧行为）仍然 `BLOCKED_GATE`；默认 3 则压进 1 页且边距 ≤21mm； 「怎么收都不减页」的稿子会整链回滚、边距回到 25mm。

## 3. model1：缺陷与代价

$$M_1(x') = \rho\, P(x') + I(x'), \qquad \rho = 15 \;\; \text{(indifference-point calibrated)}$$

### 3.1 P：页面缺陷（半硬性）

$$P(x') = \sum_k w_k\, N_k \;+\; \sum_{fe} \Big( 0.8\, \mathbf{1}[\text{spec unstable}] + 0.5\, \mathbf{1}[\text{spec} = H] \Big) \;+\; \sum_h w_{\text{hyg}}(h) \;+\; \sum_{d \in D_1} w_d\, s(d)$$

| 缺陷 | 权重 | 来源 | 无差异点 c*（I 单位） |
|---|---|---|---|
| 正文行溢出 overfull | 1.696 | 人判无差异点 | 11.5（+ 阶段 13 先验区间收窄） |
| 页面盒欠满 vbox_under（孤行寡行代理） | 1.033 | 人判无差异点 | 7.0 |
| 浮动体警告 floatwarn | 1.033 | 人判无差异点 | 7.0 |
| 表格超宽 tab_overwide | 1.033 | 人判无差异点 | 7.0 |
| `[H]` 强排 spec_H | 1.033 | 人判无差异点 | 7.0 |
| 行欠满 underfull | 0.737 | 人判无差异点 | 5.0 |
| 页面盒溢出 vbox_over | 0.737 | 人判无差异点 | 5.0 |
| 图片超宽 fig_overwide | 1.0 | **先验（未标定）** | — |

| | | | |
|---|---|---|---|
| 其余编译 Warning | 0.3 | **先验（人不可判）** | — |
| 断行质量宏缺失 | 2.0 | **先验（人不可判）** | — |
| 浮动体参数不稳定 | 0.8 | **先验（人不可判）** | — |

另有源码卫生 22 项（`HYGIENE_WEIGHT` 0.3–1.0）与页面视觉缺陷（`stranded_block` 1.2 / `near_empty` 0.6，× 严重度系数）。 P 目前按**出现次数线性累加**——同页 20 处溢出 = 20 次计。**用户 11-02 决定暂不加饱和项。**

## 3.2 ρ：缺陷 ↔ 代价的汇率

$$w_k = \frac{c_k^*}{\rho}, \qquad c_k^* : \text{ human indifference cost (in } I \text{ units) at which “keep the defect” } \equiv \text{“fix it”}$$

口径是**等边际收益**：修 1 单位缺陷的质量收益，恰好抵消 1 单位干预代价。 测量方式不是从闭环里统计「已经发生的修复」（那会偏向"修得值"的一侧， 旧值 0.341 就是这么来的），而是**直接问人**：

| 轮次 | 设计 | 结果 |
|---|---|---|
| 第一轮 | 5 类缺陷 × 3 档边距（+12/20/30mm）+ 空题 | 中位 ρ = 16.7 |
| 第二轮 | 边界加密 + 字号货币 + 空题 | 中位 ρ = 13.3 |
| 一致性复核 | 3 道空题 + 3 道明显差异题 | 6/6 通过 |
| **取值** | 两轮中位 | **ρ = 15**，区间约 [5, 32]（单人评分、5 类缺陷） |

含义：修 1 个加权缺陷，在人眼里约值 15 个代价单位——即愿意用 30mm 级别的 边距改动去换。这也是「模型过去过于死守原版心」的量化解释。

## 3.3 口径统一：从 c* 到落地权重

$$s = \frac{\sum_{k \in \mathcal{C}} w_k^{\text{before}}}{\sum_{k \in \mathcal{C}} w_k^{\text{raw}}}, \qquad w_k^{\text{final}} = s \, w_k^{\text{raw}}$$

7 项从两套不可比的口径（人判严重度 ÷ 语料频率；9 月手拍先验）统一到 c* 后， 权重和从 7.301 掉到 3.301。若不同步缩放，等于偷偷放松了「最小干预」的强度； 所以整体 ×2.212 拉回原量纲，**ρ=15 继续锚定**（口径 A）。33 题作答、空题 4/4 通过。

### 3.4 I：干预代价

$$I(x') = I_{\text{struct}}(x') + \beta\, D_{\text{content}}(x'), \qquad \beta = 50$$

| 改动 | 代价 |
|---|---|
| 页边距每偏离原稿 1mm | 0.5 |
| 字号每偏离 1 档 | 3.0 |
| 每处浮动体位置参数被规范化 / 每处图片宽度被归一 | 0.4 |
| 正文改动幅度 D_content（归一化字符多重集 Jaccard 差) | × β = 50 |

内容保留是**强偏好**而不是硬约束：语义抛光阶段要允许合法改字， 所以改正文按幅度扣分、不判死。要恢复「零改动」硬约束，把 `content_hard=True` 即可。

## 4. model2：审美量化

$$M_2(x') = A_{\text{soft}}(x') + \lambda\, A_{\text{profile}}(x'), \qquad \lambda = 0$$

### 4.1 A_soft：平滑目标形式（现口径）

$$\ell_i(p) = w_i\left(1 - e^{-d_i(p)^2/2}\right), \qquad d_i(p) = \frac{|\,x_i(p) - t_i\,|}{s_i^{\pm}}, \qquad t_i = \text{corpus median},\ \ s_i^{\pm} = \text{dist. to } p_5/p_{95}$$

$$A_{\text{soft}}(x') = \sum_i w_i\Big[\,0.5\,\text{topk}_k(\ell_i) + 0.5\,\text{mean}(\ell_i)\Big], \qquad k = \max\big(1, \text{round}(0.05\,N_{\text{pages}})\big)$$

目标 `t` 取已录用语料中位数，尺度 `s` 取到 p5 / p95 的距离； 损失在目标处为 0、两侧严格单调、有界（封顶 3.0）。页 → 文档用「最差 5% 均值 + 全体均值」 各半：既对局部异常页敏感，又不被单页主导。

这一形式是阶段 10 换掉的旧「带内恒 0」写法：旧写法会让 20 页里有 8 页总分为 0、 排序信号被抹平，且把「过满」当缺陷（与人的偏好相反）。换形式后人工排序 Spearman 0.3146 → **0.4586**，并列 8/20 → **0/20**。

### 4.2 体检结论：8 个指标里只有 3 个在干活

90 篇 / 1502 页语料 + 8 个受控坏版面变体，两套体检交叉判定：

| 指标 | 篇内损失极差 | 只看正文页 | 坏版面敏感性 | 处置 |
|---|---|---|---|---|
| max_gap（页内大空洞） | 0.283 | 0.000 | **1.384**（最强） | **保留，改口径（只算页中段）** |
| ink_ratio（墨迹密度） | 0.322 | 0.039 | 0.686 | **保留，按角色分层** |
| top_bottom_ratio（上下失衡） | 0.468 | **0.297** | 0.526 | **保留** |
| top_blank（页首留白） | 0.199 | 0.099 | 0.374 | 删（与 max_gap 正文层 ρ=0.837） |
| right_blank | 0.130 | 0.011 | 0.399（来自双栏） | 删（与 left ρ=0.876） |
| left_blank | 0.005 | 0.005 | 0.002 | 删（死数） |
| bottom_blank | **0.000** | 0.000 | 0.148 | 删（篇内完全不变） |
| band（单块内容占比） | — | — | — | 保持权重 0（阈值型，≥0.40 仍作门控判据） |

> **读法要小心：** `max_gap` 在正文页上完全不动（0.000），因为正常正文页没有大空洞—— **这恰恰是它的职责**。只看语料会把它误判成死数；必须配「坏版面敏感性」这套体检， 它在那里是最强的（1.384）。反过来， `bottom_blank` 两项指标都接近 0，删掉没有风险。

另外查出两个口径漏洞，列入 v2：① `max_gap` 会把**末页自然留白**当成页中大洞 （干净的合成稿就吃了 0.379 的罚分）；② `ink_ratio` 的变异 97% 来自页类型 （整页图页密度天然低），不按角色分层就是在量「这页是不是图页」。

### 4.3 A_profile：为什么 λ 仍然是 0

A_profile 量的是「与同会议·同角色语料的偏离」，不是「缺陷」。阶段性外部验证里， 源码级退化造成的 4 篇坏稿，它 **0/4** 与缺陷指标同向——因为 TeX 在断页处把问题吞掉了， 渲染结果逐位

不变。所以在「把缺陷敏感与常态偏离拆开」之前，λ 必须保持 0； 代码里有 `assert_lambda_allowed` 硬拦截，防止悄悄开。

## 5. 验收规则：严格改善才保留

$$\text{accept} \iff \Delta|\text{Gate}| < 0 \quad \vee \quad \big(\Delta|\text{Gate}| = 0 \ \wedge \ \Delta M_1 < 0\big) \quad \vee \quad \big(\Delta M_1 = 0 \ \wedge \ \Delta M_2 < 0\big)$$

| # | 条件 | 结果 |
|---|---|---|
| 1 | Gate 违规数减少 / 增加 | 接受 / 拒绝 |
| 2 | 双方都还有页数违规，页数不增 | 接受（压页可能需连续多档才兑现） |
| 3 | Gate 未过（不可打分） | 拒绝（$M_1$/$M_2$ 仅供诊断） |
| 4 | $M_1$ 严格改善 | 接受 |
| 5 | $M_1$ 变差 | 拒绝（$M_2$ 再好也不补偿） |
| 6 | $M_1$ 完全持平、$M_2$ 严格改善 | 接受（唯一 tie-break） |
| 7 | 其他 | 拒绝 |

每个候选都**整篇重编译 + 全局重评**，变差即回滚；失败动作跨轮 blocked； 连续 2 轮无改善才停。验收口径本身会改变优化器行为，所以口径可审计、有测试。 （历史上 v1「总分相加」把真修复拒过：修 `[H]→[tbp]` 让 A 从 17.5 降到 16.0， 但 I 升到 2.8，总分反而变高被回滚。）

## 6. 局部 vs 整体

$M_1$ 的 P 是全文按次数求和，一个烂页会被别页的好摊平；$M_2$ 本来就有局部/整体聚合—— 两条线口径不一致，报告里也看不出「哪一页最差」。阶段 15 补了一层**只做归因、不改判定**的诊断：

$$p_p = \sum_{d:\,\text{page}(d)=p} w_d\, s(d), \qquad \bar{p} = \frac{1}{N}\sum_p p_p, \qquad \text{topk}_k(p), \qquad \max_p p_p$$

| 归因对象 | 怎么落到页 |
|---|---|
| 日志类缺陷（行溢出 / 欠满 / 表格超宽） | 源码行号 → **SyncTeX** → PDF 页号 |
| 源码卫生项、`[H]` 强排、参数不稳定 | 同上（扫描自带行号） |

| | |
|---|---|
| 渲染层视觉缺陷（内容孤立、近空白页） | 本来就有页号 |
| vbox、浮动体警告、其余警告、质量宏缺失 | **归不到页**，单列「未归属」 |

实测 `examples/issues.tex`（3 页）：P 页均 1.311、最差页 1.900、全篇 5.933（其中 2.0 归不到页）。第 3 页是「近空白页」，是全篇最差的一页，但在全篇 P 里只占 10%——这就是「整体分摊平局部病灶」的具体例子。

> **边界（用户 11-02 拍定）：**不加最差页项（`ρ_peak·P_peak`）、不做同类缺陷饱和、不改 $M_1$ 公式。局部层只用于**诊断与报告**，不作为优化目标——因为动作面大多是全局的（边距、字号、浮动体参数），以单页分为目标会诱导「修好这页、害了别页」。

## 7. 实测终态（现行权重，真编译）

| 文档 | 状态 | 页数 | Gate | P | $M_1$ | $M_2$ | 说明 |
|---|---|---|---|---|---|---|---|
| demo | DONE | 6 | 0 | 0.00 | 0.00 | 1.197 | 干净稿，只注入质量宏 |
| issues | DONE | 2 | 0 | 0.30 | 4.90 | 1.232 | 残余为下划线滥用 |
| aidtest | DONE | 2 | 0 | 0.00 | 0.40 | 0.894 | 只花 0.4 的结构代价 |
| chaos | NEEDS_REVIEW | 5 | 0 | 0.74 | 13.06 | 2.549 | 残余为整页大图类 |
| nightmare | NEEDS_REVIEW | 5 | 0 | 4.40 | 67.14 | 1.742 | overfull 变贵后暴露的正文溢出 |

数据来自阶段 14 的「旧权重 vs 现行权重」A/B 实跑（`workbench-pweight-ab/`）。**accepted 动作数、页数、Gate 逐个文档完全相同**——说明这次改的是 P 的内部结构（口径更正），没有在靶稿上掀起新的取舍。$M_1$ 不可跨权重比较（尺度变了），只能比动作集合与残余缺陷归属。

## 8. 可信度与局限（必须写进论文）

1. **ρ 是单评分人、5 类缺陷**标出来的，区间约 [5, 32]；两轮中位 16.7 / 13.3。小数点后的精度没有意义。
2. **P 有 4 项仍是先验**（fig_overwide / warn / macros_missing / unstable_spec），代码里逐项标注，不冒充标定结果。

3. **指标判定对样本量敏感**：27 篇样本时 `top_blank` 被判保留、`max_gap` 被判分层； 扩到 90 篇结论才稳定。**这条本身就是方法学局限。**
4. **角色是像素代理**，不是语义角色（不知道那页是不是 references / appendix）； 真正的 roles.py 走矢量层、成本高，闭环里跑不动。
5. **A_soft 不是人类审美评分**：与人的一致性只有 20 页排序 Spearman 0.46 （n=20 时标准误约 ±0.2）与 12 对成对比较。
6. **两套口径不可混比**：在线是像素层、离线是矢量层，只能比方向，不能比绝对值。
7. **「全局最优」不声称**：只保证「评分可复现、方向可验证、退化会变差」。

## 9. 下一步

| 序 | 事项 | 依赖 |
|---|---|---|
| 1 | A_soft v2 落地：3 指标 + max_gap 位置条件 + ink_ratio 角色门控； 权重先用过渡值（A 量级 ×1.618 锚定） | 无（可立即做） |
| 2 | 30 对成对比较做 BT 权重标定，替换过渡值 | **需人工作答 20–30 分钟** |
| 3 | 改前/改后 A/B：成对命中率 + 负样本单调性 + Spearman 三重复核 | 依赖 1、2 |
| 4 | fig_overwide 构造标定（P 里唯一没标定过的项）； 第二评分人复核 ρ | 需人工作答 |
| 5 | A_profile 的「缺陷敏感 vs 常态偏离」拆分，之后才谈 λ>0 | 独立议题 |

## 10. 复现

```
cd /mnt/d/桌面/texopt

# 全量回归（含连档压页 A/B、归因恒等式、指标体检）— 332 项
python3 tests/run_tests.py

# 权重 artifact 漂移校验（代码 ↔ 落地值）
python3 tools/apply_severity_weights.py --check
python3 tools/pweight_combine.py --check
```

```
# 单页 / 整篇诊断（写进 state.json.page_diagnostics + report.md）
python3 optimize.py examples/issues.tex --outdir /mnt/d/桌面/texopt/_out

# model2 两套体检
python3 tools/soft_identifiability.py --papers 90 --workers 6
python3 tools/soft_sensitivity.py
```

---

文档生成：`python3 docs/make_formula_doc.py`（公式在 `EQS` 表里，编译成 SVG 内联，离线可看）。本页对应的模板是 `docs/scoring_report_20261102.template.html`；口径细节见 `docs/scoring/README.md` 与 `docs/stage1{2,3,4,5,6}_*.md`。